Caso Práctico: Aplicación de la Metodología CRISP-DM al Problema

Introducción

Iremos aplicando cada una de las fases de la metodología CRISP-DM al problema práctico que nos planteamos, que es la extracción y explotación de datos del entorno universitario.

Iremos numerando cada una de las fases de la metodología tal y como las hemos ido viendo anteriormente.

1. Comprensión del Negocio

1.1. Determinar los Objetivos del Negocio

1.2. Evaluación de la Situación

1.3. Determinar los Objetivos de la Minería de Datos

1.4. Realizar el Plan del Proyecto

1.1. Determinar los Objetivos del Negocio

El objetivo que se va a aplicar en este proyecto es el de hacer predicciones lo más fiables posible a partir de los datos que ya se disponen de los alumnos en una universidad.

El objetivo es proporcionar un mejor servicio de enseñanza a los alumnos y así poder captar más alumnos para que realicen sus estudios en la universidad.

1.1. Determinar los Objetivos del Negocio

Contexto

Se cuenta con una base de datos de los alumnos actualmente cursando una titulación en la universidad y también de aquellos que ya han terminado sus estudios.

Sin embargo no existe ningún estudio en profundidad sobre el comportamiento de los estudiantes de los que se puedan sacar conclusiones o patrones para hacer predicciones sobre los futuros estudiantes.

1.1. Determinar los Objetivos del Negocio

Objetivo

Hacer predicciones lo más fiables posible a partir de los datos que ya se disponen de los alumnos en una universidad y de tal forma proporcionar un mejor servicio de enseñanza a los alumnos y así poder captar más alumnos para que realicen sus estudios en la universidad.

1.1. Determinar los Objetivos del Negocio

Objetivo (Continuidad)

- Hacer predicciones acerca del tiempo que los alumnos emplean para acabar sus titulaciones.
- Predecir las notas medias de los alumnos al acabar la carrera.
- Predecir notas de asignaturas problemáticas para los alumnos.

1.1. Determinar los Objetivos del Negocio

Criterios de éxito del negocio

- Realizar predicciones sobre nuevos alumnos con un elevado porcentaje de fiabilidad de tal forma que se puedan dar consejos útiles a los ingresantes.
- Elevar el porcentaje de aprobados en aquellas asignaturas que tengan un bajo porcentaje de aprobados por parte de los alumnos.

1.2. Evaluación de la Situación

Base de datos Oracle 11g con información detallada de los alumnos que han cursado alguna de las titulaciones de la universidad desde el año 1997 hasta la actualidad.

En la DB tenemos:

- Nota de acceso a la universidad
- Escuela secundaria de procedencia del alumno
- Provincia
- Título secundario
- Otros datos personales del alumno

1.2. Evaluación de la Situación

Inventario de recursos

- Software Oracle Data Mining.
- CPU Escritorio con el siguiente hardware:
  - Marca: Packard Bell ©
  - Modelo: iMedia X1617
  - Procesador: Intel © Core 2 Quad Q6600 a 2.40 GHz
  - Memoria RAM: 3,00 GB
  - Capacidad de almacenamiento: 360 GB
  - Tarjeta gráfica: NVIDIA © GeForce 9600 GT
  - Sistema operativo: Microsoft Windows 7 Professional ©
  - Monitor TFT: Philips © 190 S de 19”

1.2. Evaluación de la Situación

Requisitos, supuestos y restricciones

Al no poder utilizar los datos personales de alumnos reales debido a cuestiones legales, se ha tenido que utilizar una base de datos ficticia con datos no reales de alumnos inventados.

1.2. Evaluación de la Situación

Costos y beneficios

- Ningún costo adicional a la universidad.
- Mejoramiento económico indirecto.

1.3. Determinar los Objetivos de la Minería de Datos

- Predecir el tiempo (en cursos académicos) que un alumno tardará en conseguir el título universitario en función de su nota de ingreso a la universidad, escuela secundaria de procedencia, provincia y titulación escogida.
- Predecir la nota media de la carrera que un alumno obtendrá cuando termine sus estudios.
- Identificar aquellas asignaturas que parecen ser más complicadas para los alumnos en cada titulación y predecir la nota que un determinado alumno obtendrá en la asignatura.

1.3. Determinar los Objetivos de la Minería de Datos

Criterios de éxito de minería de datos

- 80% de fiabilidad al realizar predicciones sobre nuevos alumnos.

1.4. Realizar el Plan del Proyecto

- **Etapa 1**: Análisis de la estructura de los datos y la información de la base de datos. Tiempo estimado: 2 semanas.
- **Etapa 2**: Ejecución de consultas para tener muestras representativas de los datos. Tiempo estimado: 1 semana.
- **Etapa 3**: Preparación de los datos (selección, limpieza, conversión y formateo, si fuera necesario) para facilitar la minería de datos sobre ellos. Tiempo estimado: 3 semanas.
- **Etapa 4**: Elección de las técnicas de modelado y ejecución de las mismas sobre los datos. Tiempo estimado: 1 semana.

1.4. Realizar el Plan del Proyecto

- **Etapa 5**: Análisis de los resultados obtenidos en la etapa anterior, si fuera necesario repetir la etapa 4. Tiempo estimado: 1 semana.
- **Etapa 6**: Producción de informes con los resultados obtenidos en función de los objetivos de negocio y los criterios de éxito establecidos. Tiempo estimado: 1 semana.
- **Etapa 7**: Presentación de los resultados finales. Tiempo estimado: 1 semana.

Nota: en paralelo a la realización de cada una de estas etapas se irá construyendo el diccionario de terminología de minería de datos (Anexo 1).

1.4. Realizar el Plan del Proyecto

Evaluación inicial de herramientas y técnicas

- Oracle Data Mining
- En cuanto a las técnicas que se van a emplear para la extracción de conocimiento:
  - Predictivas
    - Clasificación
    - Regresión
  - Descriptivas
    - Agrupamiento (clustering)
    - Reglas de asociación

2. Comprensión de los Datos

2.1. Recolectar los Datos Iniciales

2.2. Descripción de los Datos

2.3. Exploración de los Datos

2.4. Verificar la Calidad de los Datos

2.1. Recolectar los Datos Iniciales

A continuación listamos los datos adquiridos:

- Asignaturas
- Titulaciones
- Centros de enseñanza
- Alumnos
- Fechas

2.1. Recolectar los Datos Iniciales

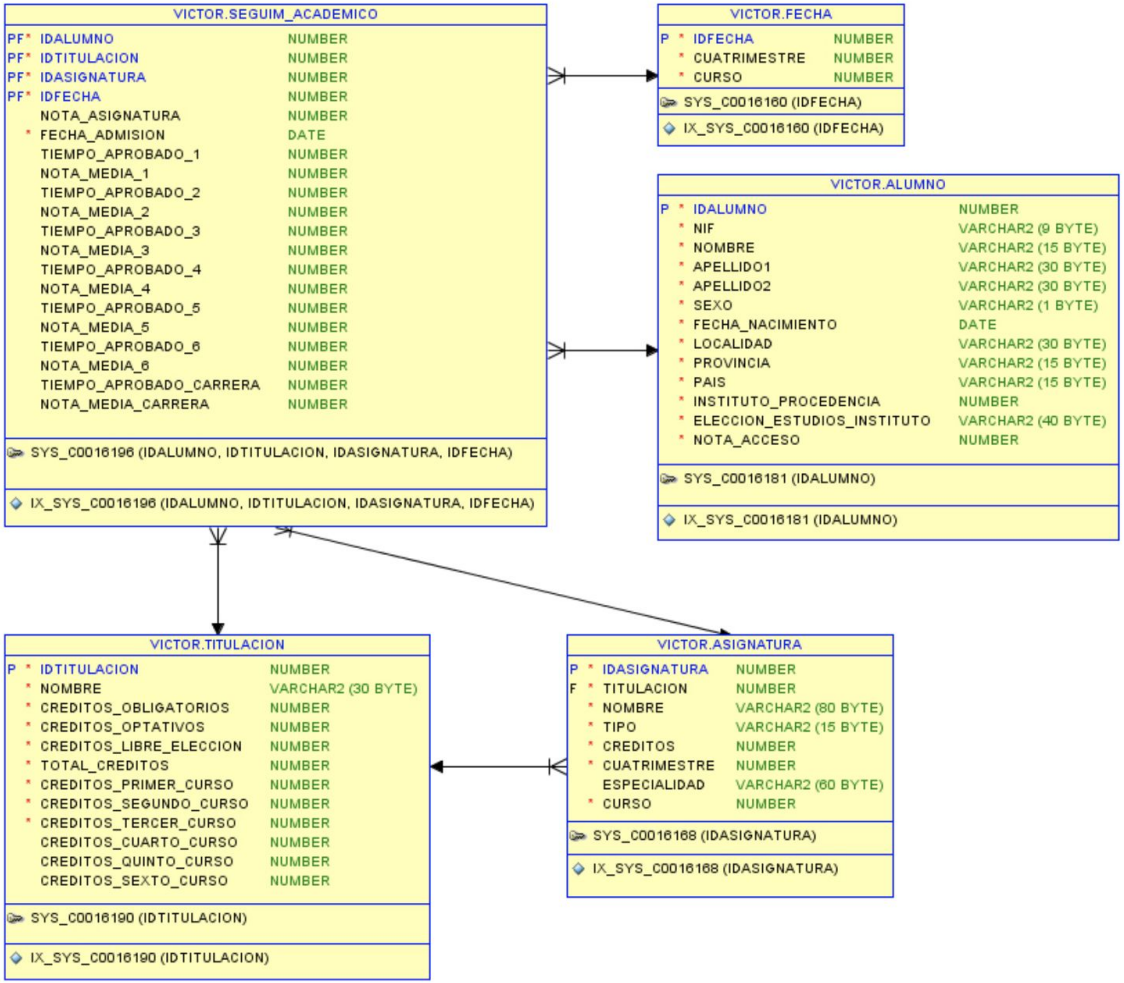
Los atributos específicos que serán útiles a la hora de hacer la minería de datos son:

- Identificador de alumno
- Nota de acceso a la universidad del alumno
- Centro de procedencia del alumno
- Identificador de la titulación
- Nota media de cada curso terminado en la universidad
- Tiempo (en cursos académicos) de aprobado de cada curso terminado en la universidad
- Identificador de la asignatura
- Fecha en la que se cursó la asignatura
- Nota obtenida en la asignatura

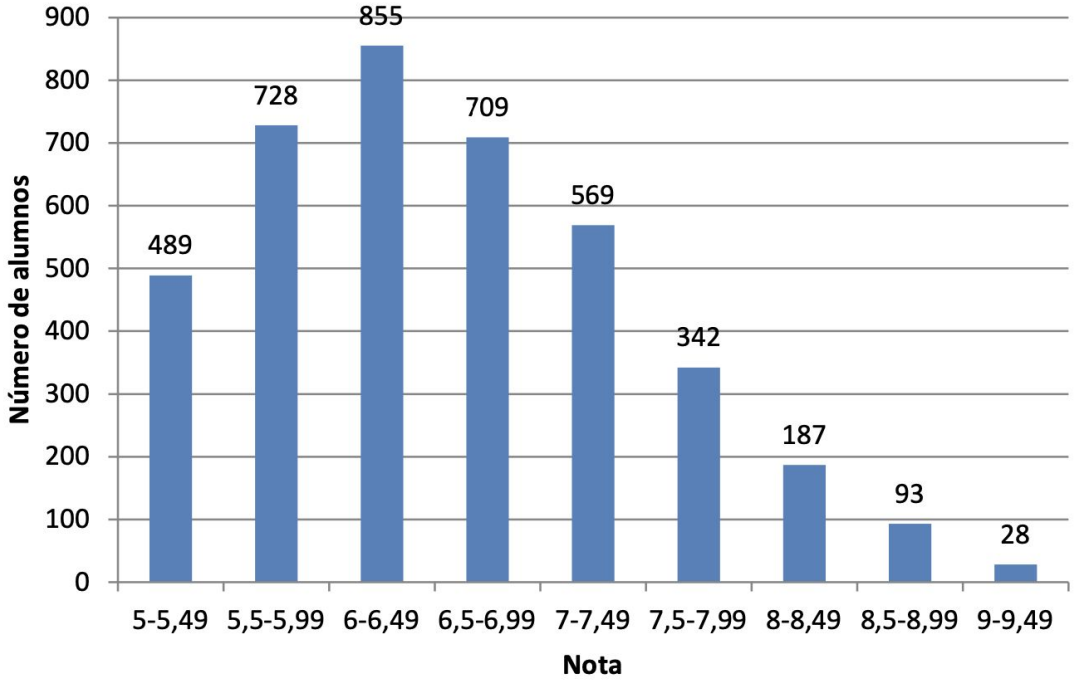
2.1. Recolectar los Datos Iniciales

Las tablas en las que se recogen los datos necesarios para la minería de datos son:

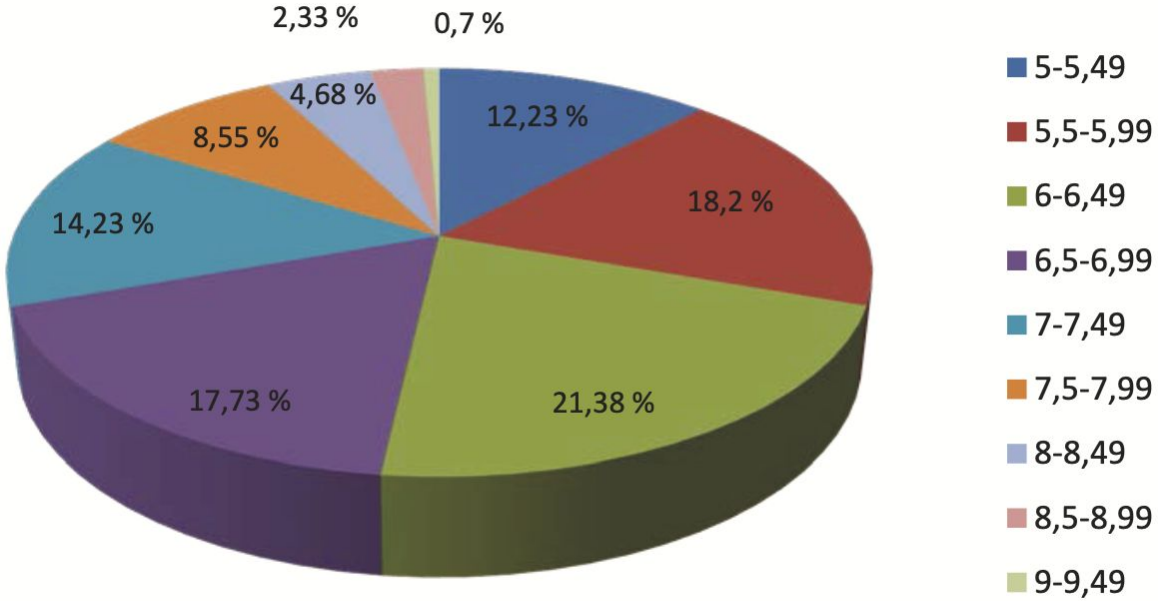
- Fecha
- Asignatura
- Alumno
- Titulación
- Seguimiento Académico


VICTOR.SEGUIM_ACADEMICO
PF* IDALUMNO NUMBER
PF* IDTITULACION NUMBER
PF* IDASIGNATURA NUMBER
PF* IDFECHA NUMBER
NOTA_ASIGNATURA NUMBER
* FECHA_ADMISION DATE
TIEMPO_APROBADO_1 NUMBER
NOTA_MEDIA_1 NUMBER
TIEMPO_APROBADO_2 NUMBER
NOTA_MEDIA_2 NUMBER
TIEMPO_APROBADO_3 NUMBER
NOTA_MEDIA_3 NUMBER
TIEMPO_APROBADO_4 NUMBER
NOTA_MEDIA_4 NUMBER
TIEMPO_APROBADO_5 NUMBER
NOTA_MEDIA_5 NUMBER
TIEMPO_APROBADO_6 NUMBER
NOTA_MEDIA_6 NUMBER
TIEMPO_APROBADO_CARRERA NUMBER
NOTA_MEDIA_CARRERA NUMBER
SYS_C0016196 (IDALUMNO, IDTITULACION, IDASIGNATURA, IDFECHA)
IX_SYS_C0016196 (IDALUMNO, IDTITULACION, IDASIGNATURA, IDFECHA)
VICTOR.FECHA
P * IDFECHA NUMBER
* CUATRIMESTRE NUMBER
* CURSO NUMBER
SYS_C0016160 (IDFECHA)
IX_SYS_C0016160 (IDFECHA)
VICTOR.ALUMNO
P * IDALUMNO NUMBER
* NIF VARCHAR2 (9 BYTE)
* NOMBRE VARCHAR2 (15 BYTE)
* APELLIDO1 VARCHAR2 (30 BYTE)
* APELLIDO2 VARCHAR2 (30 BYTE)
* SEXO VARCHAR2 (1 BYTE)
* FECHA_NACIMIENTO DATE
* LOCALIDAD VARCHAR2 (30 BYTE)
* PROVINCIA VARCHAR2 (15 BYTE)
* PAIS VARCHAR2 (15 BYTE)
* INSTITUTO_PROCEDENCIA NUMBER
* ELECCION_ESTUDIOS_INSTITUTO VARCHAR2 (40 BYTE)
* NOTA_ACCESO NUMBER
SYS_C0016181 (IDALUMNO)
IX_SYS_C0016181 (IDALUMNO)
VICTOR.TITULACION
P * IDTITULACION NUMBER
* NOMBRE VARCHAR2 (30 BYTE)
* CREDITOS_OBLIGATORIOS NUMBER
* CREDITOS_OPTATIVOS NUMBER
* CREDITOS_LIBRE_ELECCION NUMBER
* TOTAL_CREDITOS NUMBER
* CREDITOS_PRIMER_CURSO NUMBER
* CREDITOS_SEGUNDO_CURSO NUMBER
* CREDITOS_TERCER_CURSO NUMBER
CREDITOS_CUARTO_CURSO NUMBER
CREDITOS_QUINTO_CURSO NUMBER
CREDITOS_SEXTO_CURSO NUMBER
SYS_C0016190 (IDTITULACION)
IX_SYS_C0016190 (IDTITULACION)
VICTOR.ASIGNATURA
P * IDASIGNATURA NUMBER
F * TITULACION NUMBER
* NOMBRE VARCHAR2 (80 BYTE)
* TIPO VARCHAR2 (15 BYTE)
* CREDITOS NUMBER
* CUATRIMESTRE NUMBER
ESPECIALIDAD VARCHAR2 (60 BYTE)
* CURSO NUMBER
SYS_C0016168 (IDASIGNATURA)
IX_SYS_C0016168 (IDASIGNATURA)

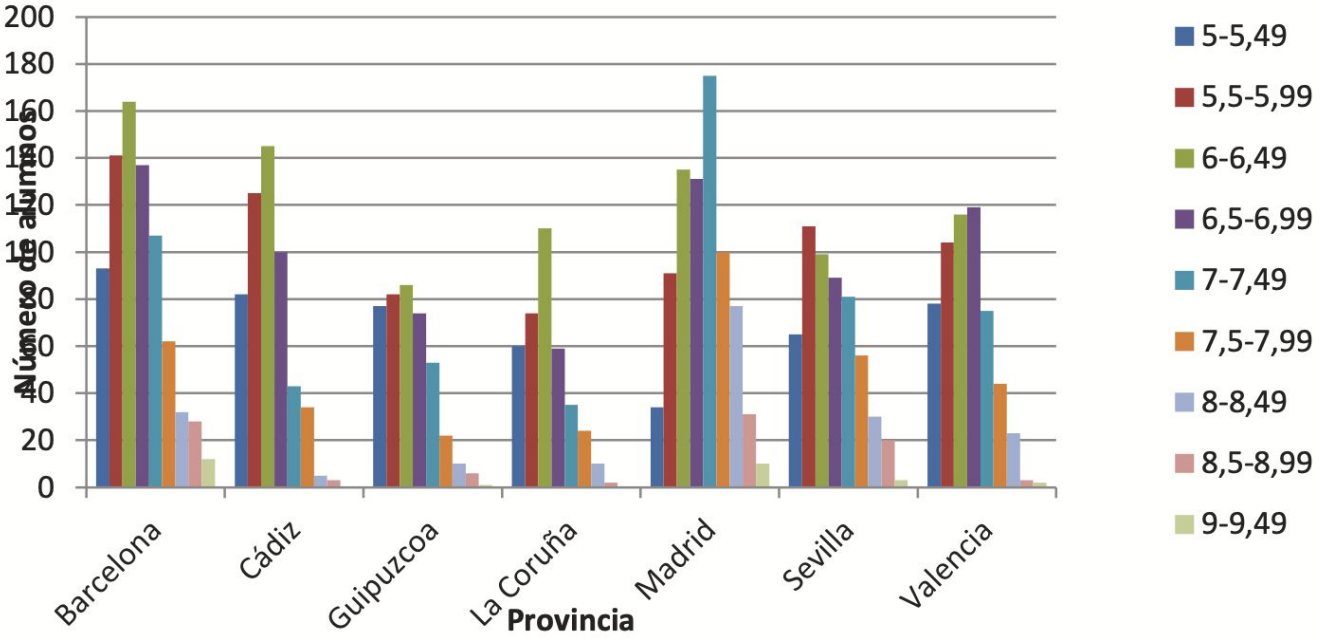
2.3. Exploración de los datos



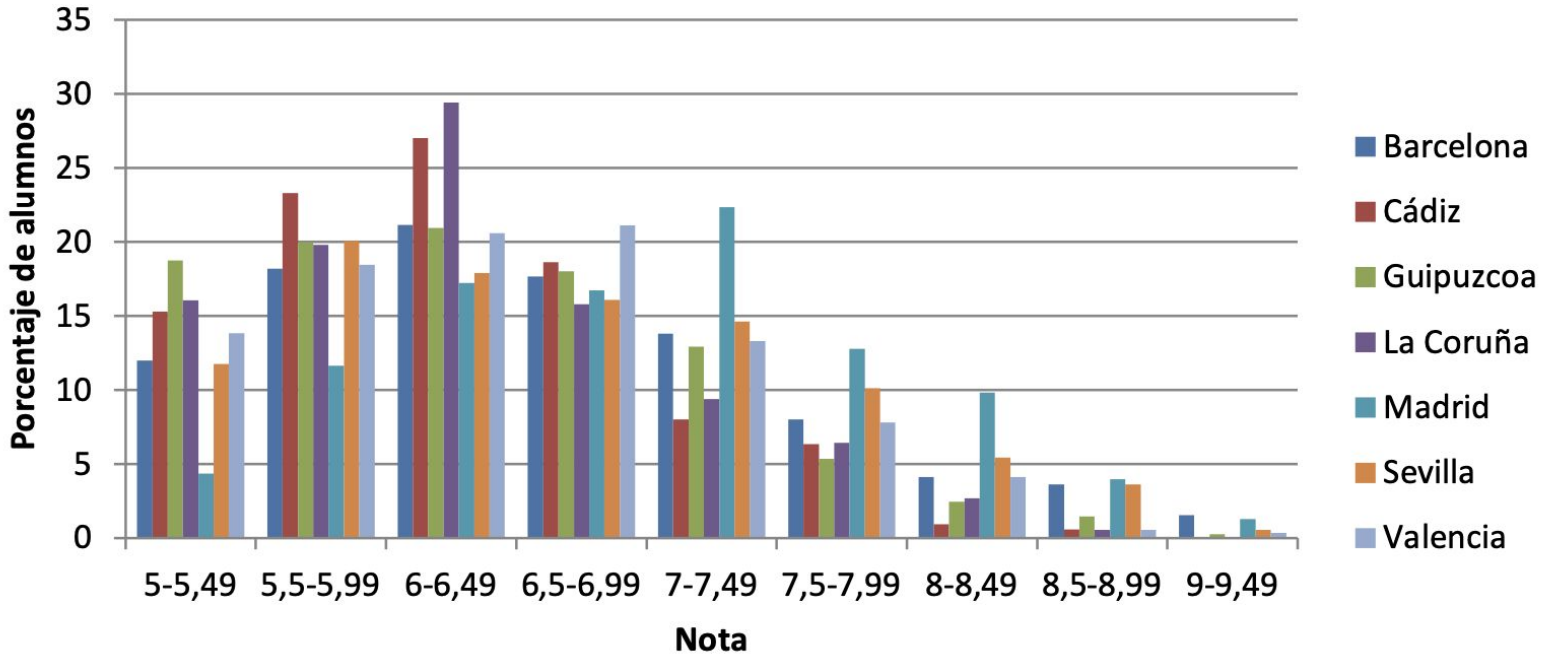
2.3. Exploración de los datos



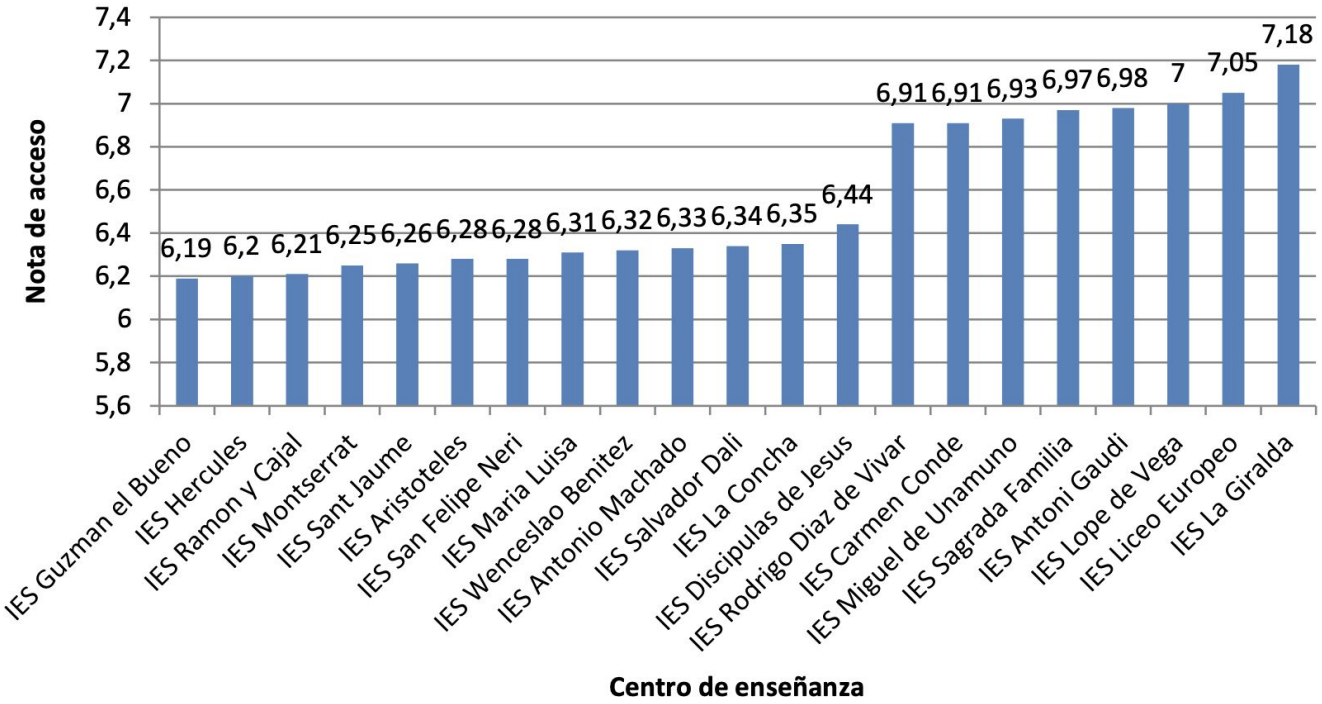
2.3. Exploración de los datos



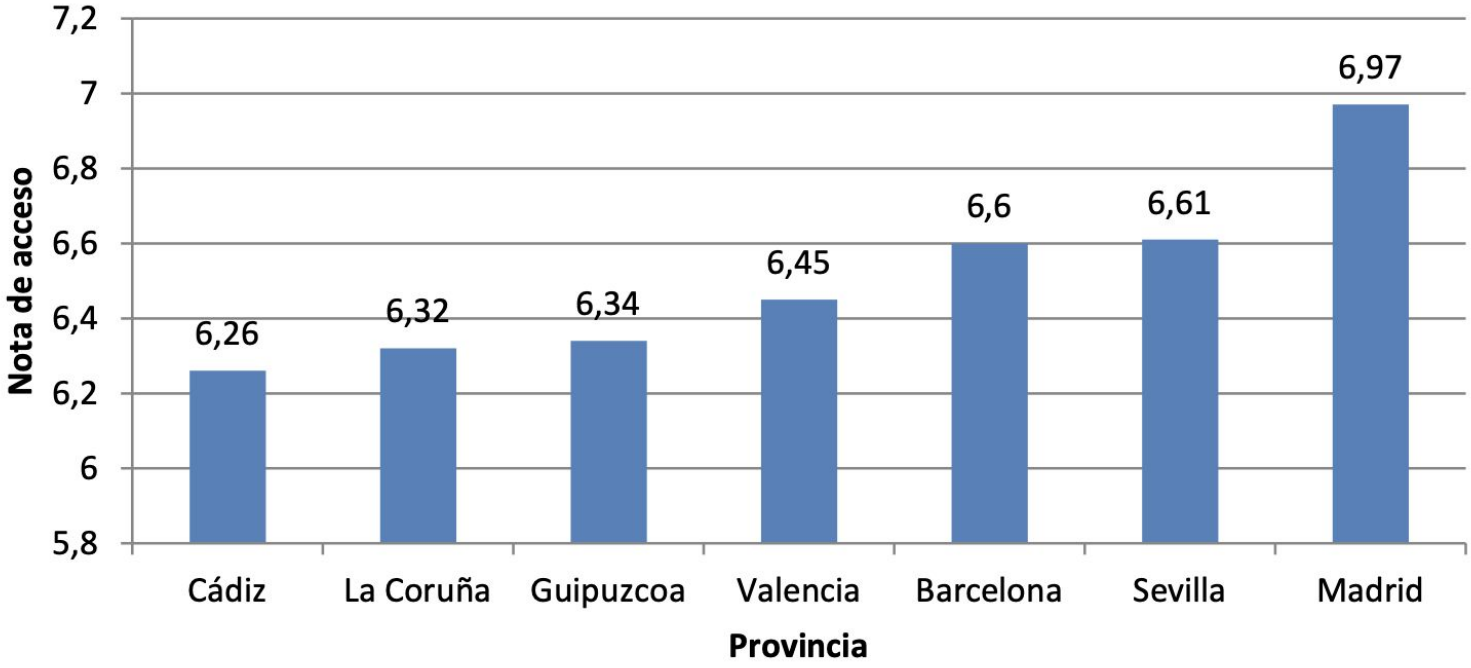
2.3. Exploración de los datos



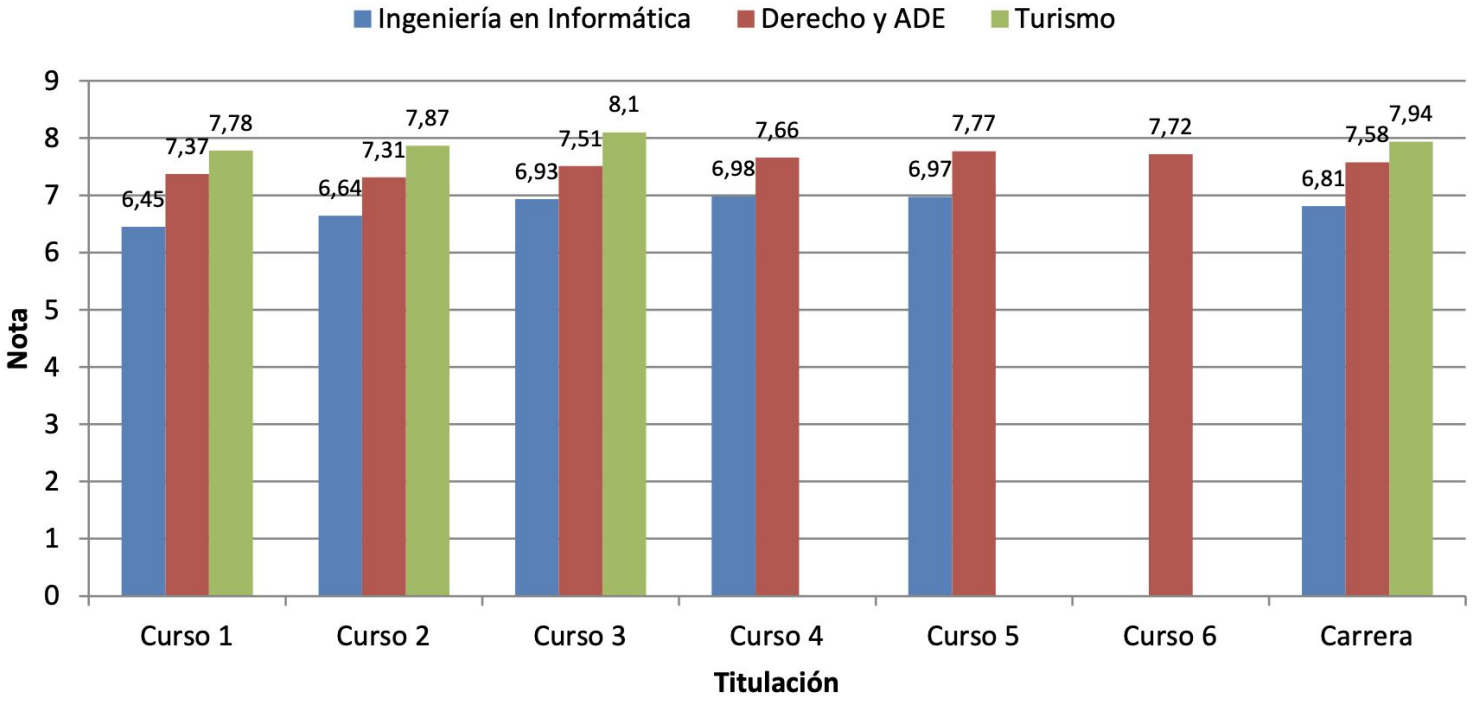
2.3. Exploración de los datos



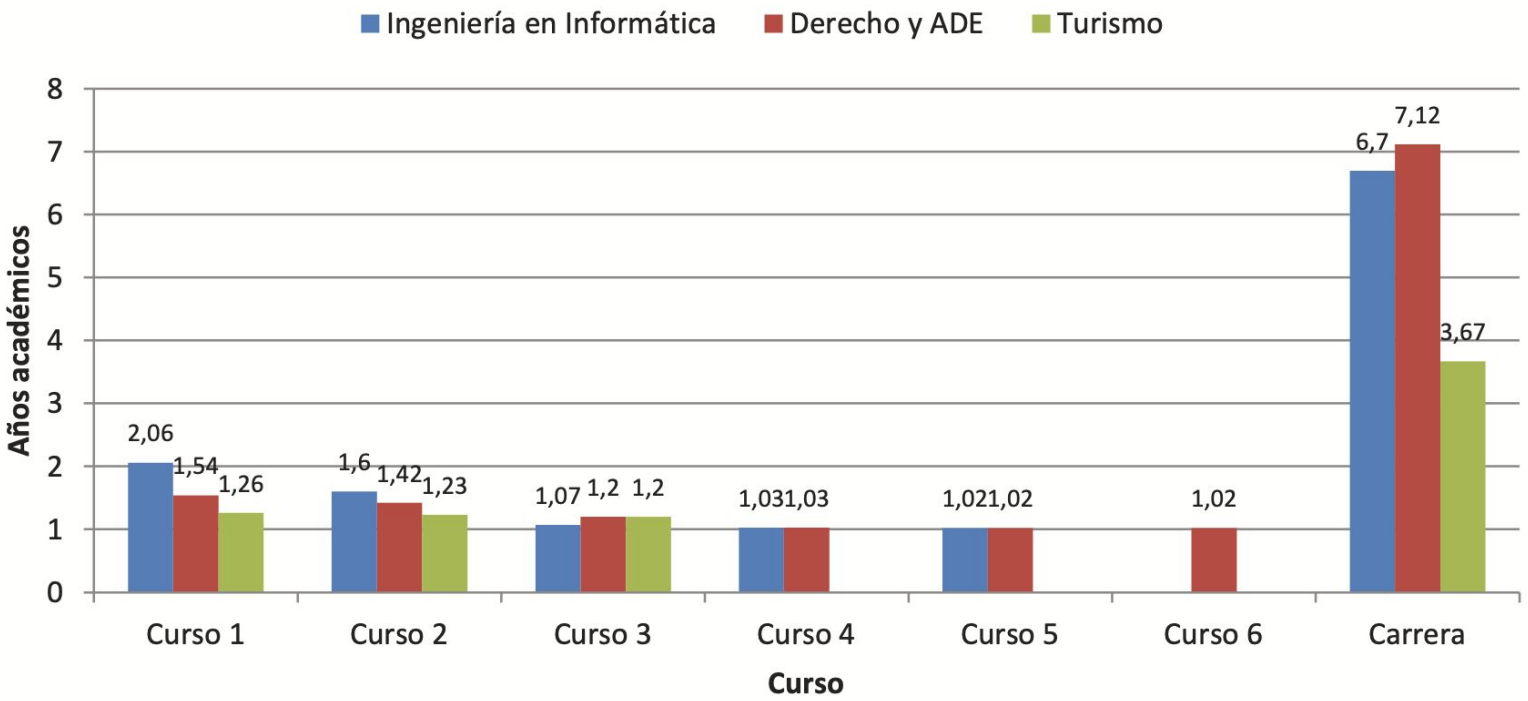
2.3. Exploración de los datos



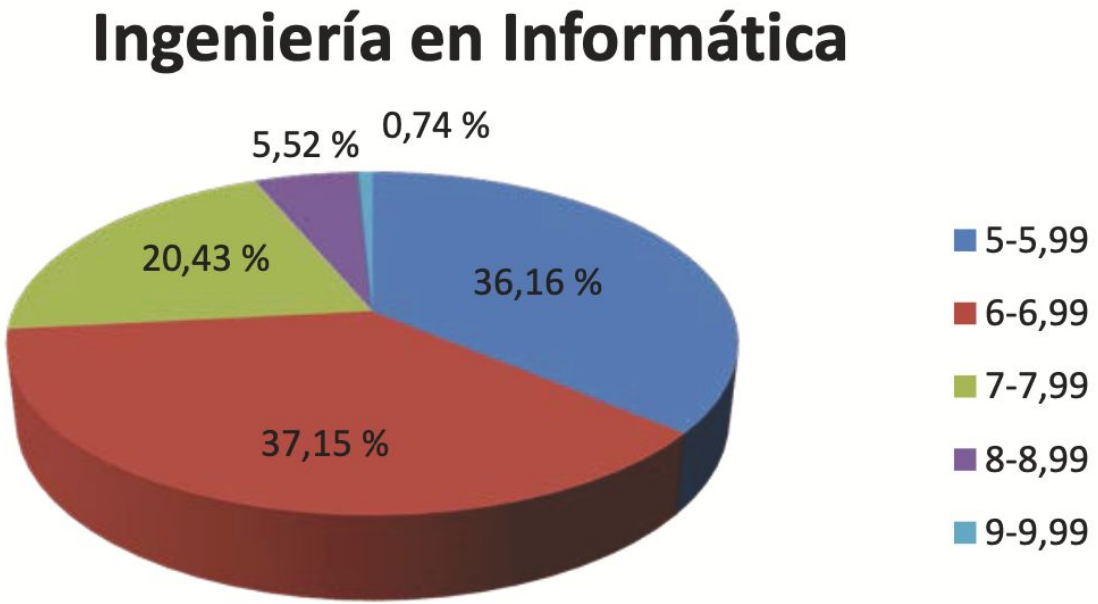
2.3. Exploración de los datos



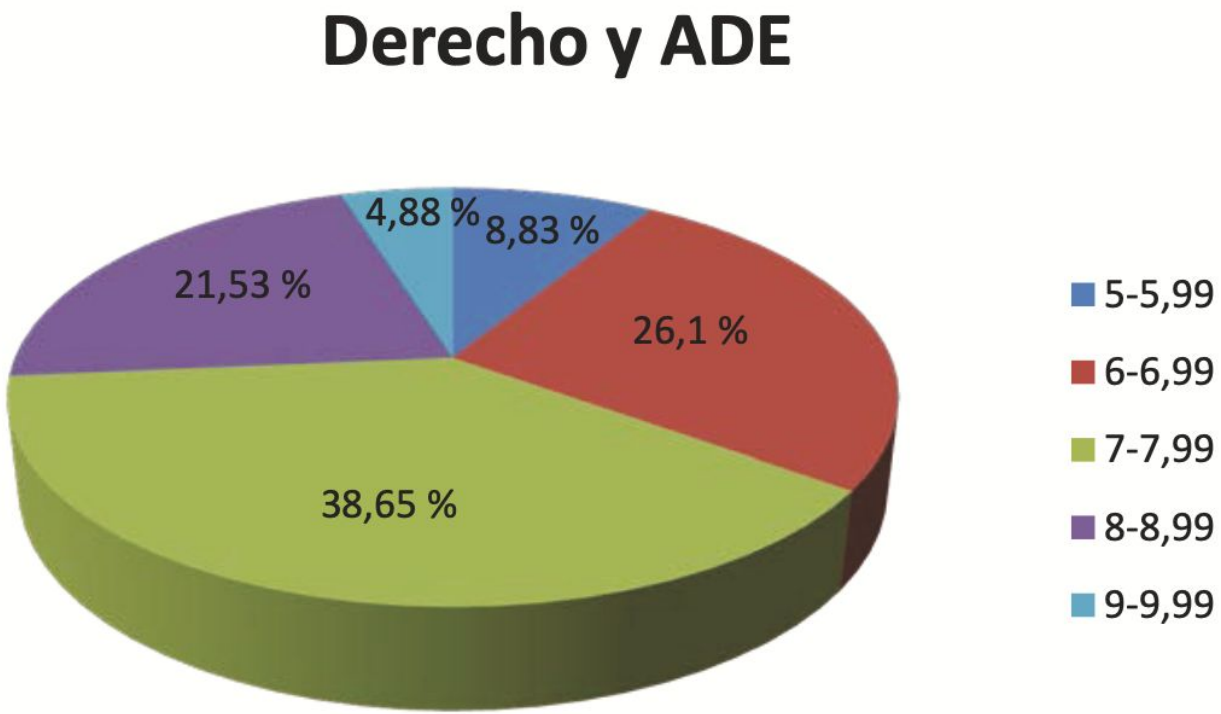
2.3. Exploración de los datos



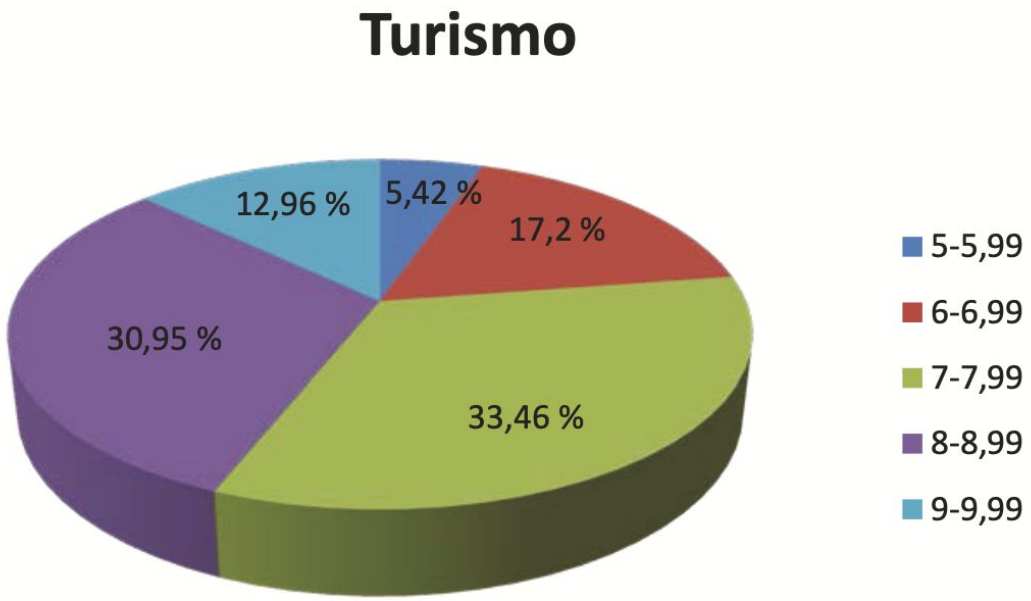
2.3. Exploración de los datos



2.3. Exploración de los datos



2.3. Exploración de los datos

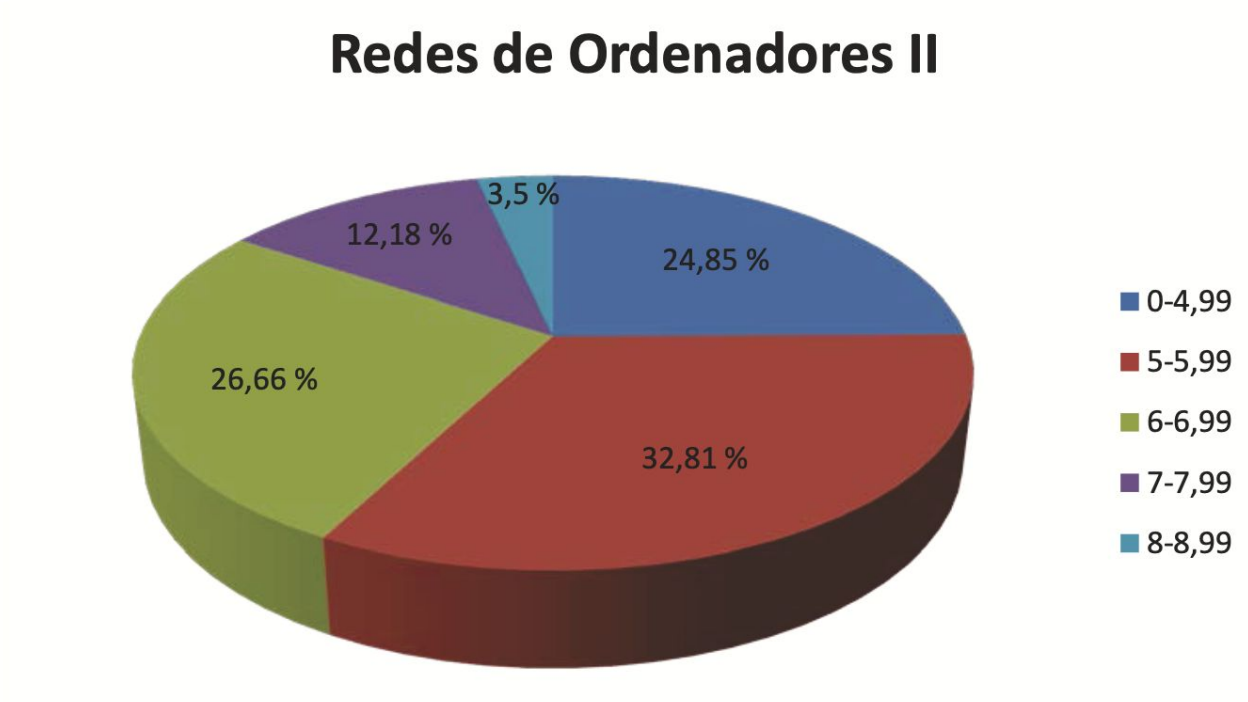


2.3. Exploración de los datos

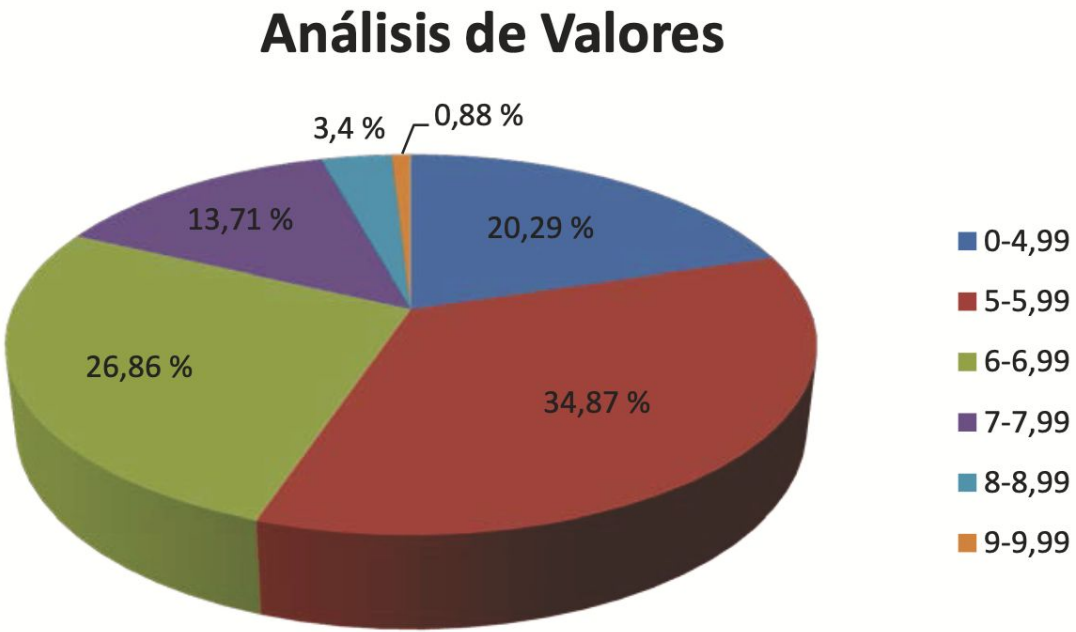
Asignaturas dentro de cada titulación cuya nota media de los alumnos son más bajas:

- Para ingeniería en informática: Redes de ordenadores II, con una nota media de 5,77.
- Para derecho y ADE: Análisis de valores, con una nota media 5,92.
- Para turismo: Recursos territoriales turísticos, con una nota media de 6,79.

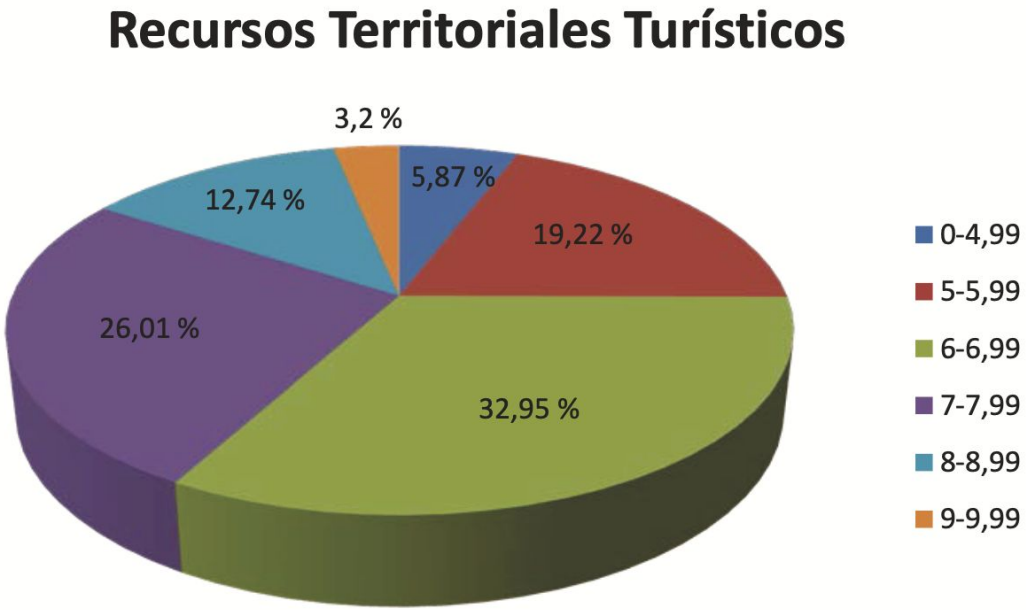
2.3. Exploración de los datos



2.3. Exploración de los datos



2.3. Exploración de los datos



2.4. Verificar la calidad de los datos

- Los datos son completos y cubren los casos requeridos para la obtención de los resultados necesarios para poder cumplir los objetivos del proyecto.
- Los datos no contienen errores. Generados automáticamente por los scripts de inserción de datos.
- Tampoco se encuentran valores fuera de rango.
- En cuanto a los valores nulos, solo los encontramos en la tabla SEGUIM_ACADEMICO. Una posible solución a la hora de hacer minería de datos con estos campos sería ignorar aquellos que contengan valores nulos.

3. Preparación de los Datos

3.1. Seleccionar los Datos

3.2. Limpiar los Datos

3.3. Construir los Datos

3.4. Integrar los Datos

3.5. Formateo de los Datos

3.1. Seleccionar los Datos

- Se van a utilizar todos los registros dentro de cada tabla que compone la base de datos.
- Hay campos dentro de estos registros que no son necesarios para nuestros objetivos de minería de datos, por lo que se puede prescindir de algunos de ellos.

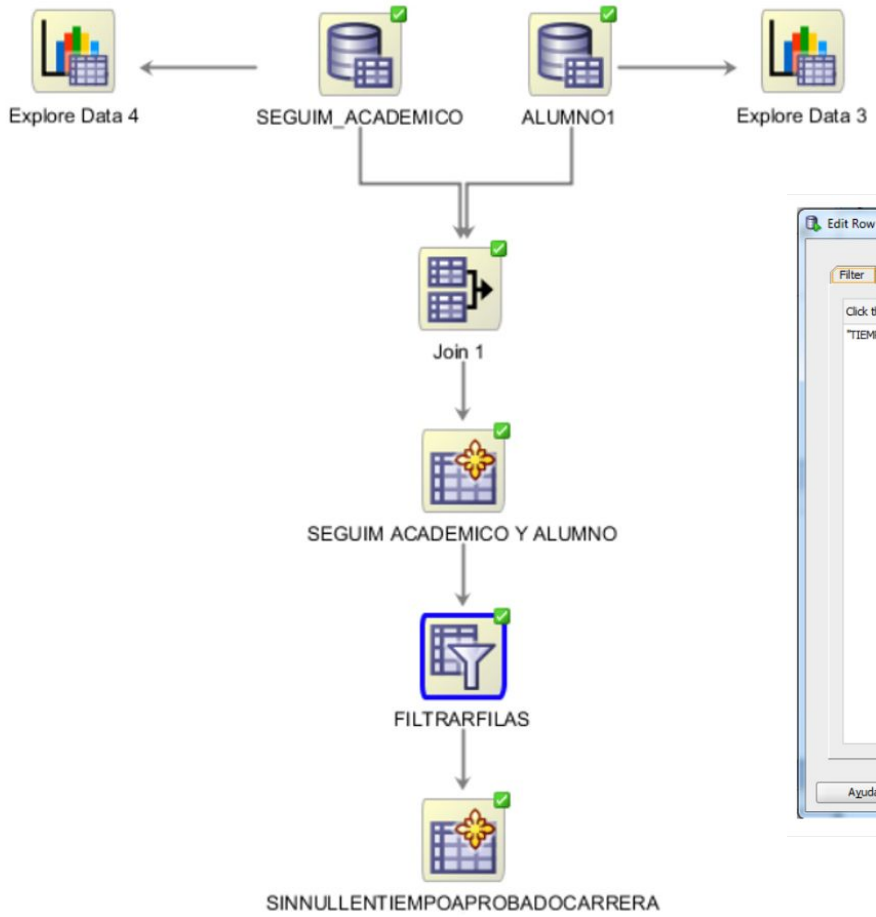
3.1. Seleccionar los Datos

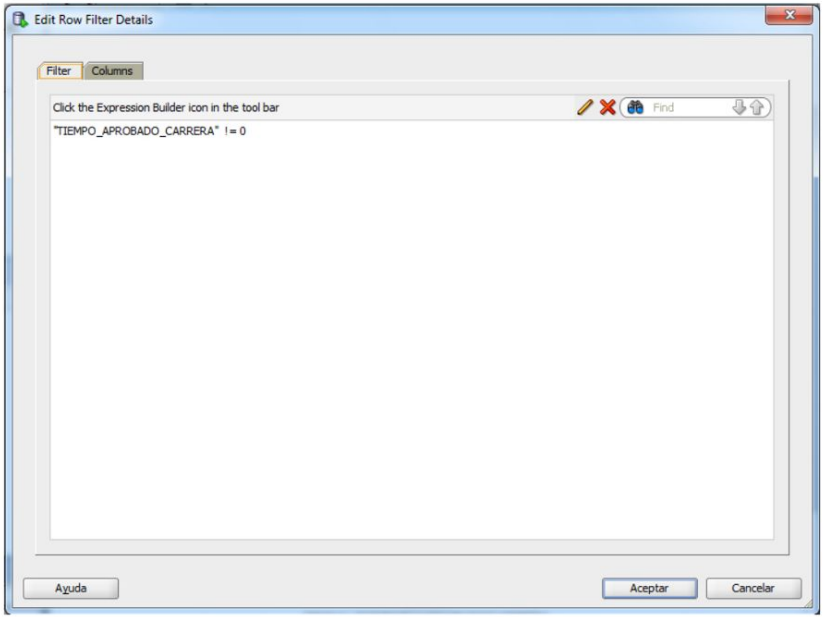
Campos seleccionados:

- **Tabla FECHA** -> IDFecha
- **Tabla ASIGNATURA** -> IDAsignatura
- **Tabla ALUMNO** -> IDAlumno, Localidad, Provincia, Instituto_procedencia, Nota_acceso
- **Tabla TITULACION** -> IDTitulacion
- **Tabla SEGUIM_ACADEMICO** -> IDAlumno, IDTitulacion, IDAsignatura, IDFecha, Nota_asignatura, Tiempo_aprobado_1, Nota_media_1, Tiempo_aprobado_2, Nota_media_2, Tiempo_aprobado_3, Nota_media_3, Tiempo_aprobado_4, Nota_media_4, Tiempo_aprobado_5, Nota_media_5, Tiempo_aprobado_6, Nota_media_6, Tiempo_aprobado_carrera o Nota_media_carrera

3.2. Limpiar los Datos

- Son datos limpios y por lo tanto no hay necesidad de hacer una limpieza más profunda sobre ellos.
- Tampoco tenemos campos en los que falten valores, más allá de los valores nulos.
- Estos valores nulos se tratarán a la hora de hacer la minería de datos simplemente ignorándolos.


Explore Data 4
SEGUIM_ACADEMICO
ALUMNO1
Explore Data 3
Join 1
SEGUIM ACADEMICO Y ALUMNO
FILTRARFILAS
SINNULLENTIEMPOAPROBADOCARRERA


Edit Row Filter Details
Filter
Columns
Click the Expression Builder icon in the tool bar
Find
"TIEMPO_APROBADO_CARRERA" != 0
Ayuda
Aceptar
Cancelar

3.3. Construir los Datos

Atributos derivados

- **Tabla ALUMNO** -> Codificar numéricamente los valores del campo que inicialmente contenía caracteres alfanuméricos con el nombre del centro de procedencia del alumno.

Registros generados

- Aparte de estas dos operaciones, no ha sido necesario generar nuevos atributos ni integrar nuevos registros a la base de datos ya que ésta está completa y ha sido creada específicamente para su uso en este proyecto.

3.4. Integrar los Datos

No ha sido necesaria la creación de nuevas estructuras (campos, registros, etc.), ni la fusión entre distintas tablas de la base de datos, ya que el programa Oracle Data Mining se encarga de realizar estas tareas automáticamente sin que el usuario tenga que crear nuevas tablas, registros o campos manualmente.

3.5. Formateo de los Datos

- Codificar con valores numéricos el nombre de cada centro de estudios de procedencia.
- No es necesario cambiar el orden de ningún campo dentro de los registros, ni tampoco la reordenación de los registros dentro de las tablas.
- Tampoco es necesario cambiar el formato de ninguno de los campos que se van a utilizar para la minería de datos ya que el formato actual es admitido por la herramienta Oracle Data Mining.

3.5. Formateo de los Datos

Los códigos para cada uno de los centros existentes en la base de datos quedaron así:

1 → I.E.S. Miguel de Unamuno

2 → I.E.S. Carmen Conde

3 → I.E.S. Liceo Europeo

4 → I.E.S. Sagrada Familia

5 → I.E.S. Sant Jaume

6 → I.E.S. Montserrat

7 → I.E.S. San Felipe Neri

8 → I.E.S. Wenceslao Benítez

9 → I.E.S. Guzmán el Bueno

10 → I.E.S. Hércules

11 → I.E.S. Discípulas de Jesús

12 → I.E.S. Rodrigo Díaz de Vivar

13 → I.E.S. Ramón y Cajal

14 → I.E.S. Aristóteles

15 → I.E.S. La Giralda

16 → I.E.S. María Luisa

17 → I.E.S. Antonio Machado

18 → I.E.S. Lope de Vega

19 → I.E.S. Antoni Gaudí

20 → I.E.S. La Concha

21 → I.E.S. Salvador Dalí

4. Modelado

4.1. Escoger la Técnica de Modelado

4.2. Generar el Plan de Prueba

4.3. Construir el Modelo

4.4. Evaluar el Modelo

4.1. Escoger la Técnica de Modelado

De los modelos que nos ofrece Oracle Data Mining, el que mejor se adapta a nuestros objetivos sería un **modelo de regresión**, puesto que **los problemas que queremos resolver son problemas de predicción y los campos que se quieren predecir contienen valores continuos**.

4.2. Generar el Plan de Prueba

El procedimiento que se empleará para probar la calidad y validez del modelo será:

- Error cuadrático medio (root mean squared error)
- Error absoluto medio (mean absolute error)
- “confianza predictiva” (predictive confidence).

Estas medidas de error las calcula automáticamente Oracle Data Mining al ejecutar los modelos de regresión.

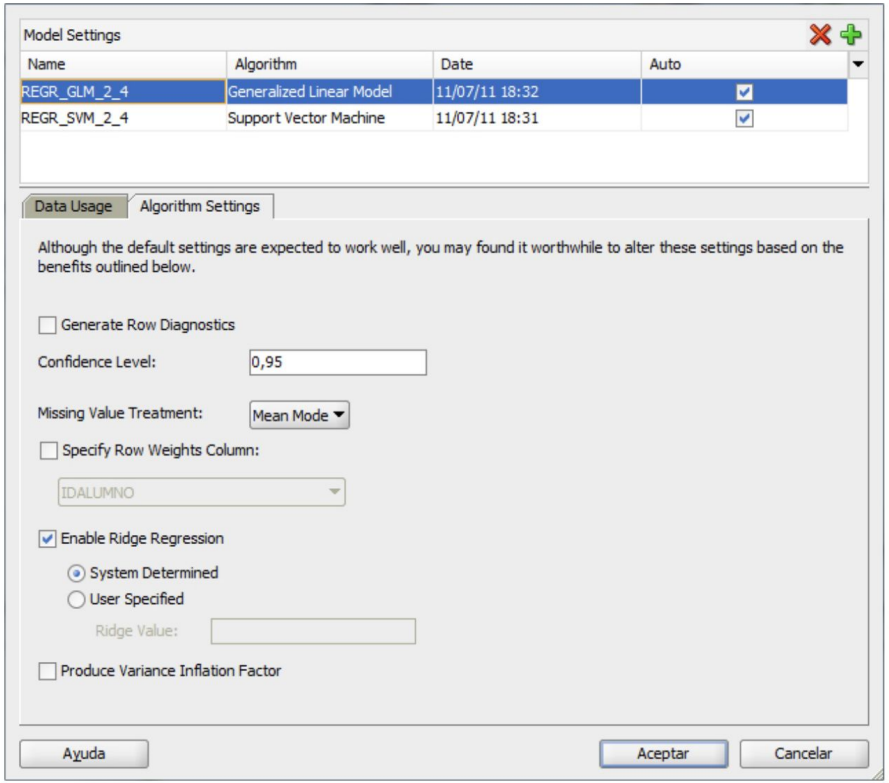
$$RMSE = \sqrt{\frac{1}{n}\sum_{j=1}^{n}(y_j - \hat{y}_j)^2} \qquad MAE = \frac{1}{n}\sum_{j=1}^{n}|y_j - \hat{y}_j|$$

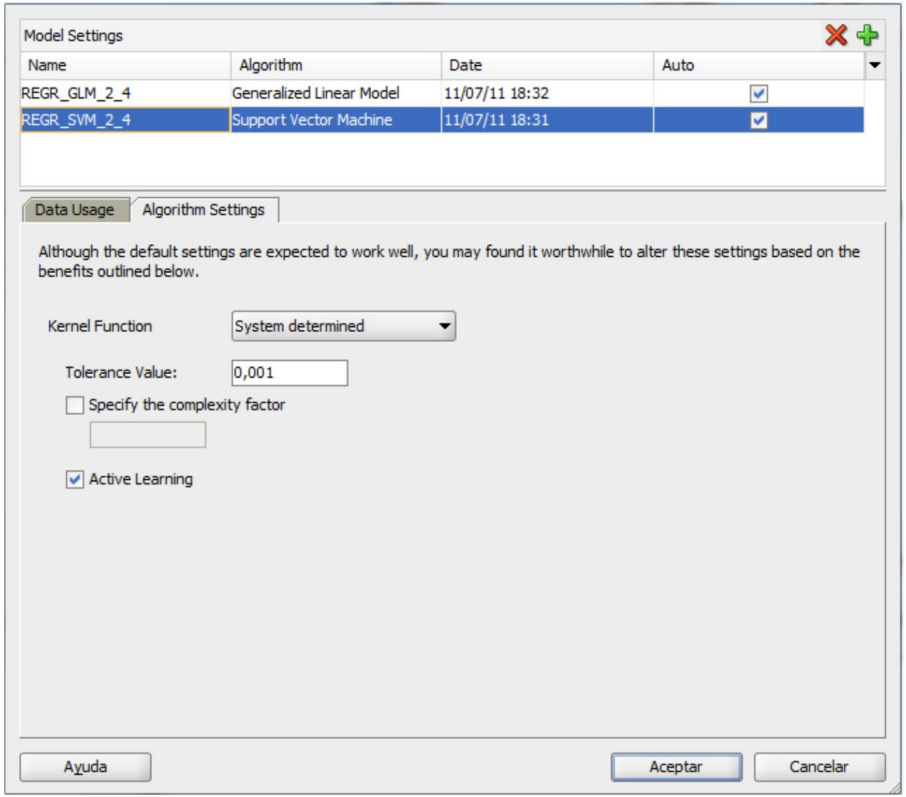
4.3. Construir el Modelo

A continuación se procederá a ejecutar el modelo elegido sobre los datos de entrenamiento. En este apartado se describirán los ajustes de parámetros del modelo que se eligen en la herramienta de minería de datos, así como la salida de dicho modelo y su descripción.

4.3. Construir el Modelo (Ajustes de Parámetros)

Objetivo 1: Predicción del tiempo que un alumno tardará en acabar la carrera.





4.3. Construir el Modelo (Ajustes de Parámetros)

Objetivo 2: Predicción de la nota media de la carrera que un alumno obtendrá al terminar sus estudios.

Para este problema el campo a predecir (objetivo) es “nota_media_carrera” y el case ID también será el “idalumno”. En cuanto a los parámetros empleados para el algoritmo de GLM, y el de SVM se utilizan los parámetros que vienen por defecto en Oracle Data Mining, que son los mismos empleados para el objetivo 1. También se utilizan los mismos filtros de columnas y filas empleados para el objetivo 1.

4.3. Construir el Modelo (Ajustes de Parámetros)

Objetivo 3: Predicción de la nota obtenida en una determinada asignatura.

En este tercer objetivo el campo que se desea predecir es “nota_asignatura” y el case ID también será el “idalumno”. Los parámetros empleados para el algoritmo de GLM, y el de SVM serán una vez más los parámetros que vienen por defecto en Oracle Data Mining.

4.3. Construir el Modelo (Ejecutar modelo)

Se ejecutan los tres modelos, uno por cada objetivo de la minería de datos, sobre un conjunto de datos de entrenamiento del 60%, con lo cual se deja el 40% de datos para el conjunto de prueba.

4.3. Construir el Modelo (Objetivo 1 - GLM)

Name	Value
ADJUSTED_R_SQUARE	0,6428702
AIC	211,59662993
COEFF_VAR	19,27969307
CORRECTED_TOTAL_DF	1444
CORRECTED_TOT_SS	4642,42491349
DEPENDENT_MEAN	5,55778547
ERROR_DF	1433
ERROR_MEAN_SQUARE	1,14816364
ERROR_SUM_SQUARES	1645,31849418
F_VALUE	237,30434475
GMSEP	1,15778401
HOCKING_SP	0,00080179
J_P	1,15769856
MODEL_CONVERGED	Yes
MODEL_DF	11
MODEL_F_P_VALUE	0
MODEL_MEAN_SQUARE	272,46421994
MODEL_SUM_SQUARES	2997,10641932
NUM_PARAMS	12
NUM_ROWS	1445
ROOT_MEAN_SQ	1,07152398
R_SQ	0,64559072
SBIC	274,90700514
VALID_COVARIANCE_MATRIX	Yes

4.3. Construir el Modelo (Objetivo 1 - SVM)

Name	Value
General	
Type	Regression
Owner	VICTOR
Model Name	REGR_SVM_2_4
Target Attribute	TIEMPO_APROBADO_CARRERA
Creation Date	26/07/11
Duration(Minutes)	0,05
Size(MB)	0,2035
Comment	
Algorithm	
Active Learning	Yes
Algorithm Name	Support Vector Machine
Automatic Preparation	On
Complexity Factor	0.896518
Kernel Cache Size	50000000
Kernel Function	Gaussian
Standard Deviation	1.026524
Tolerance	.001

4.3. Construir el Modelo (Objetivo 2 - GLM)

Name	Value
ADJUSTED_R_SQUARE	0,63592985
AIC	-2238,3395074
COEFF_VAR	6,11590976
CORRECTED_TOTAL_DF	1444
CORRECTED_TOT_SS	835,14162381
DEPENDENT_MEAN	7,50287889
ERROR_DF	1432
ERROR_MEAN_SQUARE	0,21056104
ERROR_SUM_SQUARES	301,52340462
F_VALUE	211,18904817
GMSEP	0,21247369
HOCKING_SP	0,00014714
J_P	0,21245536
MODEL_CONVERGED	Yes
MODEL_DF	12
MODEL_F_P_VALUE	0
MODEL_MEAN_SQUARE	44,46818493
MODEL_SUM_SQUARES	533,61821919
NUM_PARAMS	13
NUM_ROWS	1445
ROOT_MEAN_SQ	0,4588693
R_SQ	0,63895536
SBIC	-2169,75326759
VALID_COVARIANCE_MATRIX	Yes

4.3. Construir el Modelo (Objetivo 2 - SVM)

Name	Value
ADJUSTED_R_SQUARE	0,63592985
AIC	-2238,3395074
COEFF_VAR	6,11590976
CORRECTED_TOTAL_DF	1444
CORRECTED_TOT_SS	835,14162381
DEPENDENT_MEAN	7,50287889
ERROR_DF	1432
ERROR_MEAN_SQUARE	0,21056104
ERROR_SUM_SQUARES	301,52340462
F_VALUE	211,18904817
GMSEP	0,21247369
HOCKING_SP	0,00014714
J_P	0,21245536
MODEL_CONVERGED	Yes
MODEL_DF	12
MODEL_F_P_VALUE	0
MODEL_MEAN_SQUARE	44,46818493
MODEL_SUM_SQUARES	533,61821919
NUM_PARAMS	13
NUM_ROWS	1445
ROOT_MEAN_SQ	0,4588693
R_SQ	0,63895536
SBIC	-2169,75326759
VALID_COVARIANCE_MATRIX	Yes

4.3. Construir el Modelo (Objetivo 3 - GLM)

Name	Value
ADJUSTED_R_SQUARE	0,23701651
AIC	4180,03729593
COEFF_VAR	16,40571063
CORRECTED_TOTAL_DF	23110
CORRECTED_TOT_SS	36228,15258418
DEPENDENT_MEAN	6,66631215
ERROR_DF	23069
ERROR_MEAN_SQUARE	1,19608318
ERROR_SUM_SQUARES	27592,44296847
F_VALUE	173,8791184
GMSEP	1,19826089
HOCKING_SP	0,00005185
J_P	1,19825685
MODEL_CONVERGED	Yes
MODEL_DF	41
MODEL_F_P_VALUE	0
MODEL_MEAN_SQUARE	207,97388954
MODEL_SUM_SQUARES	8526,92947108
NUM_PARAMS	42
NUM_ROWS	23111
ROOT_MEAN_SQ	1,09365588
R_SQ	0,23837013
SBIC	4518,05598283
VALID_COVARIANCE_MATRIX	No

4.3. Construir el Modelo (Objetivo 3 - SVM)

Name	Value
General	
Type	Regression
Owner	VICTOR
Model Name	REGR_SVM_4_4
Target Attribute	NOTA_ASIGNATURA
Creation Date	29/08/11
Duration(Minutes)	0,5167
Size(MB)	0,6791
Comment	
Algorithm	
Active Learning	Yes
Algorithm Name	Support Vector Machine
Automatic Preparation	On
Complexity Factor	0.427809
Kernel Cache Size	50000000
Kernel Function	Gaussian
Standard Deviation	1.850141
Tolerance	.001

4.3. Construir el Modelo (Descripción)

Modelo para el objetivo 1

- Confianza predictiva (predictive confidence) para el algoritmo SVM tiene un valor del 68,05% y para el algoritmo GLM un valor del 40,87%.
- Error absoluto medio (mean absolute error) para el algoritmo SVM tiene un valor de 0,44 y para el algoritmo GLM un valor de 0,89.
- Error cuadrático medio (root mean square error) para el algoritmo SVM tiene un valor de 0,58 y para el algoritmo GLM un valor de 1,08.
- El valor predicho medio (mean predicted value) para el algoritmo SVM tiene un valor de 5,46 y para el algoritmo GLM un valor de 5,55.

4.3. Construir el Modelo (Descripción)

Modelo para el objetivo 2

- Confianza predictiva (predictive confidence) para el algoritmo SVM tiene un valor del 47,44% y para el algoritmo GLM un valor del 44,78%.
- Error absoluto medio (mean absolute error) para el algoritmo SVM tiene un valor de 0,34 y para el algoritmo GLM un valor de 0,35.
- Error cuadrático medio (root mean square error) para el algoritmo SVM tiene un valor de 0,41 y para el algoritmo GLM un valor de 0,44.
- El valor predicho medio (mean predicted value) para el algoritmo SVM tiene un valor de 7,5 y para el algoritmo GLM un valor de 7,49.

4.3. Construir el Modelo (Descripción)

Modelo para el objetivo 3

Confianza predictiva (predictive confidence) para el algoritmo SVM tiene un valor del 0% y para el algoritmo GLM un valor del 12,19%.

Error absoluto medio (mean absolute error) para el algoritmo SVM tiene un valor de 1,04 y para el algoritmo GLM un valor de 0,88.

Error cuadrático medio (root mean square error) para el algoritmo SVM tiene un valor de 1,30 y para el algoritmo GLM un valor de 1,09.

El valor predicho medio (mean predicted value) para el algoritmo SVM tiene un valor de 6,56 y para el algoritmo GLM un valor de 6,68.

4.4. Evaluar el modelo

	Confianza Predictiva (SVM/GLM)	Error Absoluto Medio (SVM/GLM)	Error Cuadrático Medio (SVM/GLM)
Modelo 1	✓68,05/40,87	✓0,44/0,89	✓0,58/1,08
Modelo 2	✓47,44/44,78	✓0,34/0,35	✓0,41/0,44
Modelo 3	0/12,19✓	1,04/0,88✓	1,30/1,09✓

5. Evaluación

5.1. Evaluar los Resultados

5.2. Revisar el Proceso

5.3. Determinar los Próximos Pasos

5.1. Evaluar los Resultados

Modelo para el objetivo 1

Este modelo es factible ya que se pueden hacer predicciones acerca de cuánto tiempo va a tardar un alumno en terminar la carrera con un porcentaje de fiabilidad de un 68%, el cual consideramos aceptable desde el punto de vista de los objetivos de negocio.

5.1. Evaluar los Resultados

Modelo para el objetivo 2

Este segundo modelo también es aceptable desde el punto de vista de los objetivos de negocio ya que podríamos hacer predicciones para la nota media que un alumno obtendrá una vez terminada su titulación con un porcentaje de fiabilidad de casi un 50%.

5.1. Evaluar los Resultados

Modelo para el objetivo 3

Este modelo no es viable ya que no nos ofrece suficientes garantías con tan sólo un 12% de confianza predictiva para poder realizar predicciones fiables acerca de las notas que los alumnos obtendrán en una determinada asignatura. Por este motivo, este modelo debería ser descartado o revisado.

5.1. Evaluar los Resultados

Modelos aprobados

Por las razones explicadas en este apartado y en el apartado 4.4 (evaluar el modelo) los modelos aprobados son el modelo 1 y el modelo 2 que cumplen con los criterios de éxito de negocio, mientras que el modelo 3 será descartado por no cumplir con los requisitos de negocio ni de minería de datos.

5.2. Revisar el Proceso

- El proceso hasta este punto se ha ejecutado tal y como estaba previsto.
- Para el modelo construido de cara al objetivo 3, se han obtenido valores muy deficientes
- La causa de estos malos valores posiblemente se encuentre en la base de datos utilizada
- Para el presente proyecto se ha decidido descartar este objetivo.

5.3. Determinar los Próximos Pasos

El siguiente paso a realizar en el proyecto es el de ejecutar la etapa de implantación para los objetivos 1 y 2.

6. Implantación

6.1. Planear la Implantación

6.2. Planear la Monitorización y Mantenimiento

6.3. Producir el Informe Final

6.4. Revisar el Proyecto

6.1. Planear la Implantación

- Acceso a la DB real del negocio.
- Considerar mayor complejidad en algunas fases del negocio real.
- DB Oracle, o migración a DB Oracle, o utilización de otra suite de herramientas no Oracle.
- Es posible que el objetivo 3, utilizando una DB real sea factible.

6.2. Planear la Monitorización y Mantenimiento

- Extracción y almacenamiento cuatrimestral de los datos guardando la información obtenida en formato de hoja de cálculo.
- Distribución de los datos en función de los modelos de software de minería de datos a trabajar.
- Los archivos de la explotación de datos deberán ser guardados en soporte magnético en la propia universidad, almacenándolos por ejemplo en carpetas ordenadas por procesos cuatrimestrales.
- Los resultados obtenidos en cada explotación de datos deberán ser llevados a formato de hoja de cálculo y generar gráficas de distintos tipos para una mejor visualización e interpretación de los resultados obtenidos en cada periodo.

6.3. Producir el Informe Final

- La primera etapa ha sido una de las más laboriosas por no tener una base de datos de la que partir.
- Cuando ya disponíamos de la base de datos sobre la que ejercer la minería de datos, se hizo un análisis de la estructura de los datos y la información contenida.
- Se realizaron consultas significativas en SQL para tener muestras representativas de los datos.
- Solo hizo falta apenas hacer una pequeña limpieza de los datos, conversiones o formateo de los mismos.

6.3. Producir el Informe Final (Cont.)

- Elección de las técnicas de modelado y la ejecución de dichas técnicas sobre los datos empleando la herramienta escogida para ello.
- Por último, una vez obtenidos los modelos, se analizaron para determinar la adecuación o no de los mismos. En este caso determinamos que los modelos 1 y 2 podrían ser válidos para nuestros objetivos y se descartó el 3 por no ser lo suficientemente fiable.

6.4. Revisar el Proyecto

- Evaluación de aquellas cosas que se hicieron correctamente y aquellas que no.
- Oportunidades de mejora.
- No disponer de una DB con datos reales.